

9.2 n 元关系及其应用

9.2.1 引言

在两个以上集合的元素中常常会产生某种关系。例如,学生的姓名、学生的专业以及学生的平均学分绩点之间的关系。类似地,一个航班的航空公司、航班号、出发地、目的地、起飞时间和到达时间等也有一种关系。在数学中也有这种关系。例如,有3个整数,其中第一个整数比第二个整数大,而第二个整数比第三个整数大。另一个例子是直线上的点之间的关系,即当第二个点在第一和第三个点之间时,这三个点有关系。

本节我们将研究两个以上集合的元素之间的关系。这种关系叫作 n 元关系。可以用这种关系表示计算机数据库。这种表示有助于回答对数据库中所存信息的查询,例如,哪个航班在午夜3点到4点之间降落在 O'Hare 机场? 你们学校的二年级学生哪些是主修数学或计算机科学的,并且平均学分绩点大于3.0? 公司的哪些雇员为这个公司工作不到5年但所赚的钱已经超过50 000美元?

9.2.2 n 元关系

我们从建立关系数据库理论所依据的基本定义开始。

定义1 设 $A_1, A_2, \dots, A_n$ 是集合。定义在这些集合上的 n 元关系是 $A_1 \times A_2 \times \dots \times A_n$ 的子集。这些集合 $A_1, A_2, \dots, A_n$ 称为关系的域, n 称为关系的阶。

例1 R 是 $\mathbf{N} \times \mathbf{N} \times \mathbf{N}$ 上的三元组 (a, b, c) 构成的关系,其中 a, b, c 是满足 $a < b < c$ 的整数。那么 $(1, 2, 3) \in R$, 但 $(2, 4, 3) \notin R$ 。这个关系的阶是3。它所有的域都等于自然数集。

例2 设 R 是 $\mathbf{Z} \times \mathbf{Z} \times \mathbf{Z}$ 上的三元组 (a, b, c) 构成的关系,其中的 a, b, c 构成等差数列,即 $(a, b, c) \in R$ 当且仅当存在一个整数 k , 使得 $b = a + k, c = a + 2k$, 或者 $b - a = k, c - b = k$ 。注意 $(1, 3, 5) \in R$, 因为 $3 = 1 + 2$ 和 $5 = 1 + 2 \cdot 2$, 但是 $(2, 5, 9) \notin R$, 因为 $5 - 2 = 3$, 而 $9 - 5 = 4$ 。这个关系的阶为3, 且它的所有域均等于整数集。

例3 设 R 是 $\mathbf{Z} \times \mathbf{Z} \times \mathbf{Z}^+$ 上的三元组 (a, b, m) 构成的关系,其中的 a, b, m 都是整数,且满足 $m \geq 1$ 和 $a \equiv b \pmod{m}$ 。则 $(8, 2, 3)$ 、 $(-1, 9, 5)$ 和 $(14, 0, 7)$ 都属于 R , 但 $(7, 2, 3)$ 、 $(-2, -8, 5)$ 和 $(11, 0, 6)$ 都不属于 R , 因为 $8 \equiv 2 \pmod{3}$ 、 $-1 \equiv 9 \pmod{5}$ 和 $14 \equiv 0 \pmod{7}$, 而 $7 \not\equiv 2 \pmod{3}$ 、 $-2 \not\equiv -8 \pmod{5}$ 和 $11 \not\equiv 0 \pmod{6}$ 。这个关系的阶为3, 且它的前两个域是全体整数的集合而第三个域为正整数集。

例4 设 R 是由5元组 (A, N, S, D, T) 构成的表示飞机航班的关系,其中 A 是航空公司的集合、 N 是航班号的集合、 S 是出发地的集合、 D 是目的地的集合、 T 是起飞时间的集

合。例如, 如果 Nadir 航空公司的 963 航班 15:00 从 Newark 到 Bangor, 那么 (Nadir, 963, Newark, Bangor, 15:00) 属于 R 。这个关系的阶为 5, 并且它的域是所有航空公司的集合、航班号的集合、城市的集合、城市的集合以及时间的集合。◀

9.2.3 数据库和关系

操作数据库中信息所需要的时间依赖于这些信息是怎样存储的。在大型数据库中, 每天要执行几百万次插入和删除记录、更新记录、检索记录以及从一个重叠的数据库中组合记录的操作。由于这些操作的重要性, 已经开发了多种数据库的表示方法。我们将讨论其中的一种基于关系概念的方法, 称为**关系数据模型**。

数据库由**记录**组成, 这些记录是由域构成的 n 元组。这些域是 n 元组的数据项。例如, 学生记录的数据库可以由包含学生的姓名、学号、专业、平均学分绩点(GPA)的域构成。关系数据模型把记录构成的数据库表示成一个 n 元关系。于是, 学生记录可以表示成形如(学生姓名, 学号, 专业, GPA)的 4 元组。包含 6 条记录的一个数据库样本是:

(Ackermann, 231455, 计算机科学, 3.88)

(Adams, 888323, 物理学, 3.45)

(Chou, 102147, 计算机科学, 3.49)

(Goodfriend, 453876, 数学, 3.45)

(Rao, 678543, 数学, 3.90)

(Stevens, 786576, 心理学, 2.99)

用于表示数据库的关系也称为**表**, 因为这些关系常常用表来表示。表中的每个列对应于数据库的一个属性。例如, 表 1 显示了同样的学生数据库。这个数据库的属性是学生姓名、学号、专业和平均学分绩点(GPA)。

表 1 学生

学生姓名	学 号	专 业	GPA
Ackermann	231 455	计算机科学	3.88
Adams	888 323	物理学	3.45
Chou	102 147	计算机科学	3.49
Goodfriend	453 876	数学	3.45
Rao	678 543	数学	3.90
Stevens	786 576	心理学	2.99

当 n 元组的某个域的值能够确定这个 n 元组时, n 元关系的这个域就叫作**主键**。这就是说, 当关系中没有两个 n 元组在这个域有相同的值时, 这个域就是主键。

常常要从数据库中增加或删除记录。由于这一点, 一个域是主键的性质是随时间而改变的。所以, 应该选择那种无论数据库怎样改变都能继续存在的域作为主键。一个关系当前含有的所有 n 元组称为该关系的**外延**。数据库更持久的内容, 包括它的名字和属性, 则称为数据库的**内涵**。选择主键的时候, 应当选择那种能够为本数据库所有可能的外延充当主键的域。要做到这一点, 就必须认真考察数据库的内涵, 以便理解可能在外延中出现的 n 元组集。

例 5 假设将来不再增加 n 元组, 对于表 1 所示的 n 元关系, 哪些域可作为主键?

解 因为在这个表中, 对应每个学生的姓名只有一个 4 元组, 学生姓名的域可作为主键。类似地, 在这个表中, 学号是唯一的, 学号的域也可作为主键。但是, 所学专业的域不是主键, 因为有多包含同样专业的 4 元组。平均学分绩点的域也不是主键, 因为有 2 个 4 元组包含了同样的 GPA。◀

在一个 n 元关系中, 域的组合也可以唯一地标识 n 元组。当一组域的值确定一个关系中的 n 元组时, 这些域的笛卡儿积就叫作**复合主键**。

例6 对于表1中的 n 元关系,假设不再增加 n 元组,专业域与平均学分绩点域的笛卡儿积是复合主键吗?

解 这个表中没有两个4元组有同样的专业和同样的GPA,因此这个笛卡儿积是一个复合主键。

因为主键和复合主键用于唯一地标识数据库中的记录,当新的记录被加入这个数据库时,保持主键的有效性是非常重要的。因此,应该对每个新记录做检查,以保证在这个或这些相应的域中每个新记录与表中所有其他的记录不同。例如,若没有两个学生有同样的学号,使用学号作为学生记录的主键是有意义的。一个大学不应该使用姓名域作为主键,因为有可能两个学生有同样的姓名(如 John Smith)。

9.2.4 n 元关系的运算

存在多种作用于 n 元关系上的运算,以构成新的 n 元关系。综合应用这些运算,能够回答对数据库中满足特定条件的所有 n 元组的查询。

n 元关系上一个最基本的运算是在这个 n 元关系中确定满足特定条件的所有 n 元组。例如,我们想在学生记录的数据库找出计算机科学专业的所有学生的记录;找出所有平均学分绩点在3.5以上的学生;找出所有计算机科学专业的平均学分绩点在3.5以上的学生。为完成这些任务,我们使用选择运算符。

定义2 设 R 是一个 n 元关系, C 是 R 中元素可能满足的一个条件。那么选择运算符 s_C 将 n 元关系 R 映射到 R 中满足条件 C 的所有 n 元组构成的 n 元关系。

例7 为了找出表1所示的 n 元关系 R 中计算机科学专业的学生记录,我们使用运算符 s_{C_1} ,其中 C_1 是条件专业=“计算机科学”。结果是两个4元组(Ackermann, 231455, 计算机科学, 3.88)和(Chou, 102147, 计算机科学, 3.49)。类似地,为了在这个数据库找出平均学分绩点在3.5以上的学生记录,我们使用运算符 s_{C_2} ,其中 C_2 是条件 $GPA > 3.5$ 。结果是两个4元组(Ackermann, 231455, 计算机科学, 3.88)和(Rao, 678543, 数学, 3.90)。最后,为找出计算机科学专业的GPA在3.5以上的学生记录,我们使用运算符 s_{C_3} ,其中 C_3 是条件(专业=“计算机科学” $\wedge$ $GPA > 3.5$)。结果由一个4元组(Ackermann, 231455, 计算机科学, 3.88)构成。

使用投影,可以删去关系中每条记录的相同的域,从而得到一个新的 n 元关系。

定义3 投影 $P_{i_1, i_2, \dots, i_m}$,其中 $i_1 < i_2 < \dots < i_m$,将 n 元组 $(a_1, a_2, \dots, a_n)$ 映射到 m 元组 $(a_{i_1}, a_{i_2}, \dots, a_{i_m})$,其中 $m \leq n$ 。

换句话说,投影 $P_{i_1, i_2, \dots, i_m}$ 删除了 n 元组的 $n-m$ 个分量,保留了第 $i_1, i_2, \dots, i_m$ 个分量。

例8 当对4元组(2, 3, 0, 4)、(Jane Doe, 234111001, 地理学, 3.14)以及 (a_1, a_2, a_3, a_4) 使用投影 $P_{1,3}$ 时,结果是什么?

解 $P_{1,3}$ 把这些4元组分别映射到(2, 0)、(Jane Doe, 地理学)和 (a_1, a_3) 。

例9说明了怎样使用投影来产生新的关系。

例9 当对表1中的关系使用投影 $P_{1,4}$ 时,结果是什么?

解 当使用投影 $P_{1,4}$ 时,表的第二列和第三列被删除,得到了表示学生姓名和平均学分绩点的有序对。表2给出了这个投影的结果。

当对一个关系的表使用投影时,有可能使行变少。当关系中的某些 n 元组在投影的 m 个分量中每个分量的值都相同,且只在被删除的分量中有不同的值时,就会出现这种情况。如例10所示。

例10 当对表3中的关系使用投影 $P_{1,2}$ 时,可得到什么表?

解 表 4 给出了当对表 3 使用投影 $P_{1,2}$ 时得到的关系。注意在使用了这个投影后，行数减少。

表 2 GPAs

学生姓名	GPA
Ackermann	3.88
Adams	3.45
Chou	3.49
Goodfriend	3.45
Rao	3.90
Stevens	2.99

表 3 注册

学 生	专 业	课 程
Glauser	生物学	BI 290
Glauser	生物学	MS 475
Glauser	生物学	PY 410
Marcus	数学	MS 511
Marcus	数学	MS 603
Marcus	数学	CS 322
Miller	计算机科学	MS 575
Miller	计算机科学	CS 455

当两个表中具有某些相同的域时，连接运算可将这两个表合成一个表。例如，一个表中的域包含航空公司、航班号和登机口，另一个表中的域包含航班号、登机口和起飞时间。可以将这两个表合成一个包含航空公司、航班号、登机口和起飞时间域的表。

表 4 专业

学 生	专 业
Glauser	生物学
Marcus	数学
Miller	计算机科学

定义 4 设 R 是 m 元关系， S 是 n 元关系。连接运算 $J_p(R, S)$ 是 $m+n-p$ 元关系，其中 $p \leq m$ 和 $p \leq n$ ，它包含了所有的 $(m+n-p)$ 元组 $(a_1, a_2, \dots, a_{m-p}, c_1, c_2, \dots, c_p, b_1, b_2, \dots, b_{n-p})$ ，其中 m 元组 $(a_1, a_2, \dots, a_{m-p}, c_1, c_2, \dots, c_p)$ 属于 R 且 n 元组 $(c_1, c_2, \dots, c_p, b_1, b_2, \dots, b_{n-p})$ 属于 S 。

换句话说，连接运算符 J_p 将 m 元组的后 p 个分量与 n 元组的前 p 个分量相同的第一个关系中的所有 m 元组和第二个关系的所有 n 元组组合起来产生了一个新的关系。

例 11 当用连接运算符 J_2 组合表 5 和表 6 中的关系时，所得到的关系是什么？

解 连接运算符 J_2 产生的关系如表 7 所示。

表 5 教学课程

教授	系	课号
Cruz	动物学	335
Cruz	动物学	412
Farber	心理学	501
Farber	心理学	617
Grammer	物理学	544
Grammer	物理学	551
Rosen	计算机科学	518
Rosen	数学	575

表 6 教室安排

系	课号	教室	时间
计算机科学	518	N521	2 : 00P. M.
数学	575	N502	3 : 00P. M.
数学	611	N521	4 : 00P. M.
物理学	544	B505	4 : 00P. M.
心理学	501	A100	3 : 00P. M.
心理学	617	A110	11 : 00A. M.
动物学	335	A100	9 : 00A. M.
动物学	412	A100	8 : 00A. M.

表 7 教学安排

教授	系	课号	教室	时间
Cruz	动物学	335	A100	9 : 00A. M.
Cruz	动物学	412	A100	8 : 00A. M.
Farber	心理学	501	A100	3 : 00P. M.
Farber	心理学	617	A110	11 : 00A. M.
Grammer	物理学	544	B505	4 : 00P. M.
Rosen	计算机科学	518	N521	2 : 00P. M.
Rosen	数学	575	N502	3 : 00P. M.

从已知关系产生新关系的运算除了投影和连接运算以外还有其他运算。对这些运算的描述可以在讨论数据库理论的书中找到。

9.2.5 SQL

数据库查询语言 SQL (Structured Query Language, 结构化查询语言), 可以用来实现本节所描述的运算。例 12 说明了 SQL 命令与 n 元关系上的运算的关系。

例 12 通过使用 SQL 对表 8 做一次关于航班的查询来说明怎样用 SQL 来表达查询。SQL 语句如下:

```
SELECT Departure_time
FROM Flights
WHERE Destination='Detroit'
```

是用于在航班数据库中找出满足条件: $\text{Destination} = \text{'Detroit'}$ 的 5 元组, 并求投影 P_5 (在起飞时间属性上)。输出是一个以底特律为目的, 包含航班时间的列表, 即 08:10、08:47 和 09:44。SQL 语句使用 FROM 子句标识查询语句作用到的 n 元关系, WHERE 子句说明选择运算的条件, 而 SELECT 子句说明将被使用的投影运算。(注意: SQL 使用 SELECT 表示一个投影, 而不是一个选择运算。这是一个令人遗憾的术语不一致的例子。)

表 8 航班

航空公司	航班号	通道	目的地	起飞时间
Nadir	122	34	底特律	08:10
Acme	221	22	丹佛	08:17
Acme	122	33	安克雷奇	08:22
Acme	323	34	檀香山	08:30
Nadir	199	13	底特律	08:47
Acme	222	22	丹佛	09:10
Nadir	322	34	底特律	09:44

例 13 说明 SQL 怎样做涉及多个表的查询。

例 13 SQL 语句

```
SELECT Professor, Time
FROM Teaching_assignments, Class_schedule
WHERE Department='Mathematics'
```

用于找出在数据库(表 7)中满足 $\text{Department} = \text{'Mathematics'}$ 条件的 5 元组的投影 $P_{1,5}$, 这个数据库是由表 5 中的教学课程和表 6 中的教室安排进行连接运算 J_2 得到的。输出仅包含一个 2 元组 (Rosen, 3:00P. M.)。这里的 SQL FROM 子句用于求出两个不同数据库的连接。

本节我们仅仅接触到关系数据库的基本概念。更多的信息可以在 [AhU195] 中找到。

9.2.6 数据挖掘中的关联规则

现在我们将介绍来自数据挖掘 (data mining) 的概念, 这是一门旨在从数据中获取有用信息的学科。特别是, 我们将讨论可以从事务数据库中收集到的信息。我们将专注于超市事务, 但我们提出的想法与其他广泛的应用相关。

关于事务, 我们指的是客户在访问商店期间购买的一些商品的集合, 如 {牛奶、鸡蛋、面包} 或 {橙汁、香蕉、酸奶、奶油}。商店收集可用于帮助他们管理业务的大型事务数据库。我们将讨论如何使用这些数据库来解决这个问题: 如果已知客户同时购买一个或多个特定商品的集合, 那么他们购买某个商品的可能性有多大?

我们把商店里的每一件商品都称为项, 项集合称为项集。 k 项集是一个包含恰好 k 项的项集。术语事务和购物篮与项集同义。当商店中有 n 个商品 $a_1, a_2, \dots, a_n$ 待售时, 每个事务都

可以用一个 n 元组 $b_1, b_2, \dots, b_n$ 表示, 其中 b_i 是二进制变量, 它告诉我们 a_i 是否发生在这个事务中。也就是说, 如果 a_i 在这个事务中, 则 $b_i=1$, 否则 $b_i=0$ 。(注意, 我们只关心某项是否发生在事务中, 而不关心它发生了多少次。)我们可以用形为(事务号, $b_1, b_2, \dots, b_n$)的 $(n+1)$ 元组表示事务。所有这些 $(n+1)$ 元组的集合构成了事务数据库。

我们现在定义与购买特定项集相关的问题研究中使用的其他术语。

定义 5 在事务集合 $T=\{t_1, t_2, \dots, t_k\}$ 中, 其中 k 是正整数, 项集 I 的计数记为 $\sigma(I)$, 是包含在该项集中的事务数。即

$$\sigma(I) = |\{t_i \in T \mid I \subseteq t_i\}|$$

项集 I 的支持度, 是 I 包含在从 T 中随即选择的事务中的概率。即

$$\text{support}(I) = \frac{\sigma(I)}{|T|}$$

对于特定的应用, 会指定一个支持度阈值 s 。频繁项集挖掘是寻找支持度大于等于 s 的项集 I 的过程。这些项集被称为频繁项集。

例 14 在卖苹果、梨、苹果酒、甜甜圈和芒果的展台上, 早盘交易如表 9 所示。在表 10 中, 我们给出了相应的二进制数据库, 其中每个记录都是一个 $(n+1)$ 元组, 由事务号和表示该项集的二进制条目组成。因为苹果出现在 8 个事务中的 5 个中, 所以我们得到 $\sigma(\{\text{苹果}\})=5$, $\text{support}(\{\text{苹果}\})=5/8$ 。同样, 由于项集{苹果, 苹果酒}是 8 个事务中 4 个事务的子集, 因此我们有 $\sigma(\{\text{苹果}, \text{苹果酒}\})=4$, $\text{support}(\{\text{苹果}, \text{苹果酒}\})=4/8=1/2$ 。

表 9 一个事务集

事务号	项	事务号	项
1	{苹果, 梨, 芒果}	5	{苹果, 苹果酒, 甜甜圈}
2	{梨, 苹果酒}	6	{梨, 苹果酒, 甜甜圈}
3	{苹果, 苹果酒, 甜甜圈, 芒果}	7	{梨, 甜甜圈}
4	{苹果, 梨, 苹果酒, 甜甜圈}	8	{苹果, 梨, 苹果酒}

表 10 表 9 中事务的二进制数据库

事务号	苹果	梨	苹果酒	甜甜圈	芒果
1	1	1	0	0	1
2	0	1	1	0	0
3	1	0	1	1	1
4	1	1	1	1	0
5	1	0	1	1	0
6	0	1	1	1	0
7	0	1	0	1	0
8	1	1	1	0	0

如果我们将支持度阈值设置为 0.5, 那么如果某项在 8 个事务中的至少 4 个事务中出现, 该项就是频繁项。因此, 有了这个支持度阈值, 苹果、梨、甜甜圈和苹果酒是频繁项。项集{苹果, 苹果酒}是频繁项集, 但是项集{甜甜圈, 梨}不是频繁项集。◀

若已知顾客会购买某个项集中的所有商品(可能只是一个商品), 则可以使用一组事务来帮助我们预测顾客是否会购买某个特定的商品。在讨论这类问题之前, 我们先介绍一些术语。如果 S 是一组项的集合, T 是一组事务的集合, 那么关联规则就是形如 $I \rightarrow J$ 的蕴含式, 其中 I 和 J 是 S 的不相交的子集。尽管这个符号借用了逻辑里蕴含的符号, 但它的含义并不完全是可类比的。关联规则 $I \rightarrow J$ 不是这样的命题, 即当 I 是事务的子集时, J 也必须是事务的子集。相反, 关联规则的强度是根据它的支持度(包含 I 和 J 的事务频率)以及置信度(包含 J 时也包

含 I 的事务频率)来衡量的。

定义6 若 I 和 J 是事务集 T 的子集, 则

$$\text{support}(I \rightarrow J) = \frac{\sigma(I \cup J)}{|T|}$$

和

$$\text{confidence}(I \rightarrow J) = \frac{\sigma(I \cup J)}{\sigma(I)}$$

关联规则 $I \rightarrow J$ 的支持度, 即包含 I 和 J 的事务的分数, 是一个有用的度量。因为低支持度值告诉我们, 包含 I 中所有项和 J 中所有项的项集是很少被购买的; 而高支持度值告诉我们, 它们是在很大一部分事务中被一起购买的。注意, 关联规则 $I \rightarrow J$ 的置信度是已知一个事务包含 I 中的所有项, 它将包含 I 和 J 中所有项的条件概率。因此, $I \rightarrow J$ 的置信度越大, J 成为包含 I 的事务的子集的可能性就越大。

Extra
Examples

例 15 对于例 14 中的事务集, 关联规则 {苹果酒, 甜甜圈} $\rightarrow$ {苹果} 的支持度和置信度是多少?

解 关联规则的支持度是 $\sigma(\{\text{苹果酒, 甜甜圈}\} \cup \{\text{苹果}\}) / |T|$ 。因为 $\sigma(\{\text{苹果酒, 甜甜圈}\} \cup \{\text{苹果}\}) = \sigma(\{\text{苹果酒, 甜甜圈, 苹果}\}) = 3$, $|T| = 8$, 可得这条规则的支持度是 $3/8 = 0.375$ 。

该规则的置信度是 $\sigma(\{\text{苹果酒, 甜甜圈}\} \cup \{\text{苹果}\}) / \sigma(\{\text{苹果酒, 甜甜圈}\}) = 3/4 = 0.75$ 。◀

数据挖掘中的一个重要问题是寻找强关联规则, 这些规则的支持度大于或等于最小支持度, 且置信度大于或等于最小置信度。找到有效的算法来确定强关联规则十分重要, 因为可用项的数量可能非常大。例如, 一家超市可能有数万甚至数十万的商品库存。通过计算所有可能的关联规则的支持度和置信度, 以寻找有足够大的支持度和置信度的关联规则的蛮力方法是不可行的, 因为此类关联规则的数量是指数级的(见练习 41)。目前, 研究人员已经开发出几种广泛使用的比蛮力更有效的算法。这些算法首先查找频繁项集, 然后将注意力集中到查找到的频繁项集上, 寻找所有具有高置信度的关联规则。详细信息请参阅数据挖掘相关文献, 如 [AG15]。

尽管我们仅以商场中的购物篮为例展示了关联规则, 但它们在其它各类应用中也非常有用。例如, 关联规则可用于改进医疗诊断, 其中项集是测试结果或症状的集合, 事务是在患者记录中找到的测试结果和症状的集合。关联规则也可用在搜索引擎中, 其中项集是关键字, 事务是网页上的单词集合。使用关联规则还可以发现抄袭的情况, 其中项集是句子的集合, 事务是文档的内容。关联规则在计算机安全的各个方面也发挥着有益的作用, 例如入侵检测, 其中项集是模式的集合, 事务是网络攻击期间传输的字符串。感兴趣的读者可以通过搜索网页找到更多这样的应用程序。